SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

삼성청년 SW·AI아카데미

데이터 크롤링 프로젝트

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로! Enabling People

프로젝트에 필요한 배경지식

Confidential

데이터 수집(Data Collection)이란?

- 산재한 정보를 목적에 맞는 형태로 추출 및 저장 하는 과정을 의미합니다
- 가공되지 않은 상태(Raw Data)의 정보는 프로젝트나 모델 학습에 바로 활용하기 어렵습니다
- 따라서 데이터 수집은 분석 및 활용 가능한 구조적 데이터로 전환하는 첫 단계입니다.

Confidential

웹 데이터 수집의 장점

- 실시간으로 업데이트되는 세상의 흐름을 즉시 반영할 수 있습니다.
- 사용자의 실제 목소리(댓글, 리뷰 등)가 담긴 생생한 데이터를 확보합니다.
- 웹에 존재하는 방대한 정보를 내 프로젝트에 변환하여 활용 가능합니다.

Confidential

우리가 직접 수집해야 하는 이유

- 실제 프로젝트에서는 바로 사용할 수 있는 데이터가 항상 존재하지 않습니다
- 공개 API가 없거나, 호출 횟수,형식 제약이 있는 경우가 많습니다
- 필요한 데이터는 있지만, 흩어져 있는 경우도 많습니다

Confidential

데이터 수집 하는방법 1 : API

- 정해진 방법을 통해 데이터를 제공받습니다 (받아오는 것)

Confidential

데이터 수집 하는방법 2 : 스크래핑

- 웹 페이지에서 직접 추출 (긁어 오는 것)

Confidential

데이터 수집 하는방법 3 : 증강 데이터

- 기존 데이터로 새 데이터 생성(만들어 내는 것)

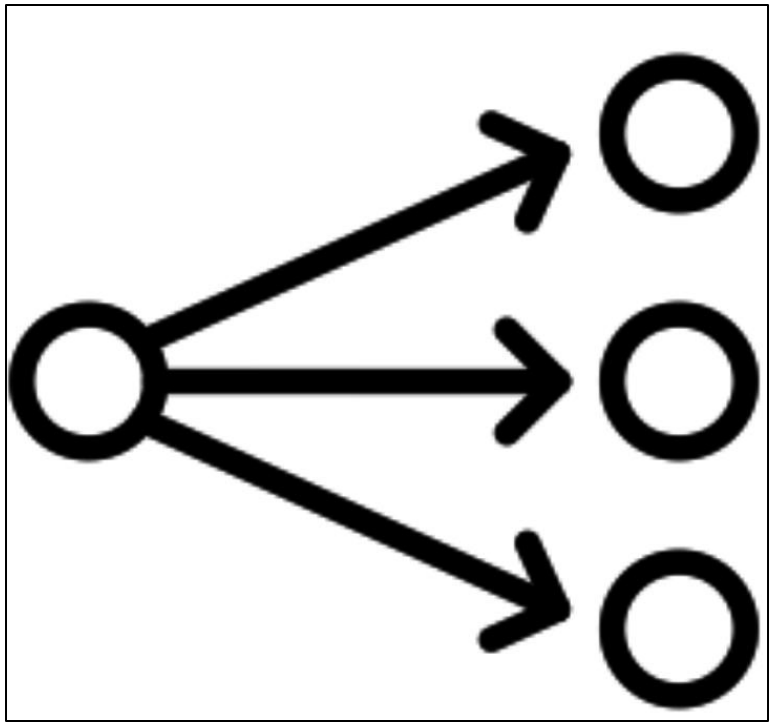

Confidential

언제 어떤 방법을 사용할까?

- 상황에 따라 수집 방법을 선택합니다

수집 방법	난이도	정밀도	추천 상황
API	하	최상	공식 데이터가 존재할 때 (가장 우선순위)
스크래핑	중	상	API는 없지만 웹에 정보가 공개되어 있을 때
증강	중	중	수집된 데이터가 너무 적어 분석이 불가능할 때

Confidential

최우선은 API를 이용합니다

- API를 활용할 수 없는경우 웹 스크래핑 & 크롤링을 고려합니다
- 데이터가 부족하다면 데이터 증강으로 보강합니다
- 데이터 수집에는 정답이 아니라 우선순위와 선택 기준이 있습니다

Confidential

챕터의 포인트

- 핵심용어 정리
- 실습

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로! Enabling People

핵심 용어 정리

Confidential

핵심 용어

- Data Collection : 웹에 존재하는 정보를 프로젝트에서 사용할 수 있는 데이터 형태로 가져오는 과정입니다
- Crawling : 여러 웹 페이지를 자동으로 이동하며 데이터가 존재하는 페이지나 URL을 수집하는 과정입니다
- Scraping : 특정 웹 페이지에서 필요한 데이터만 선택적으로 추출하는 과정입니다.
- Preprocessing : 수집한 데이터르 사용 가능한 형태로 정리하고 정제하는 과정입니다
- Data Augmentation : 기존 데이터를 기반으로 새로운 데이터를 생성하여 데이터의 양과 다양성을 늘리는 과정입니다
- Pipeline : 데이터 수집 -> 전처리 -> 증강 -> 저장까지의 전체 흐름을 하나의 과정으로 묶은 개념입니다

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로! Enabling People

실습

Confidential

실습 목표

- **데이터 수집(스크래핑) -> 전처리 -> 증강 -> 저장까지 진행하는 Data** Pipeline 구축

실습 목표

Confidential

Selenium을 활용한 실시간 데이터 수집과 LLM 데이터 증강

- Selenium을 활용하여 웹사이트에서 데이터를 수집
- 수집된 데이터를 전처리
- LLM을 활용해 텍스트 데이터 증강
- 원본 데이터와 가공,증강 데이터 통합 출력

Confidential

정적 페이지 크롤링

- 정적 페이지 : HTML 코드가 고정되어 있고, 데이터가 바뀌지 않음
- 사용 라이브러리 : request, BeautifulSoup
- http://quotes.toscrape.com/tag/love/

Confidential

동적 페이지 크롤링

- 동적 페이지 : 사용자와 상호작용하여 페이지의 데이터가 변할 수 있음
- 사용 라이브러리 : selenium, BeautifulSoup
- https://www.google.com

Confidential

검색 결과 추출

- 실습2에서 진행한 내용중 “필요한 부분만 추출”
- 사용 라이브러리 : selenium, BeautifulSoup
- https://www.google.com

Confidential

검색 결과 저장

- 실습3에서 진행한 내용을 모아 텍스트 파일로 저장
- 사용 라이브러리 : selenium, BeautifulSoup
- https://www.google.com

Confidential

토스 증권 데이터 수집

- 메인 페이지 접속부터 수집할 데이터의 위치파악
- 사용 라이브러리 : selenium
- https://www.tossinvest.com/
- 실습 전에 전반적인 과정 확인

Confidential

토스증권 접속

- https://www.tossinvest.com/

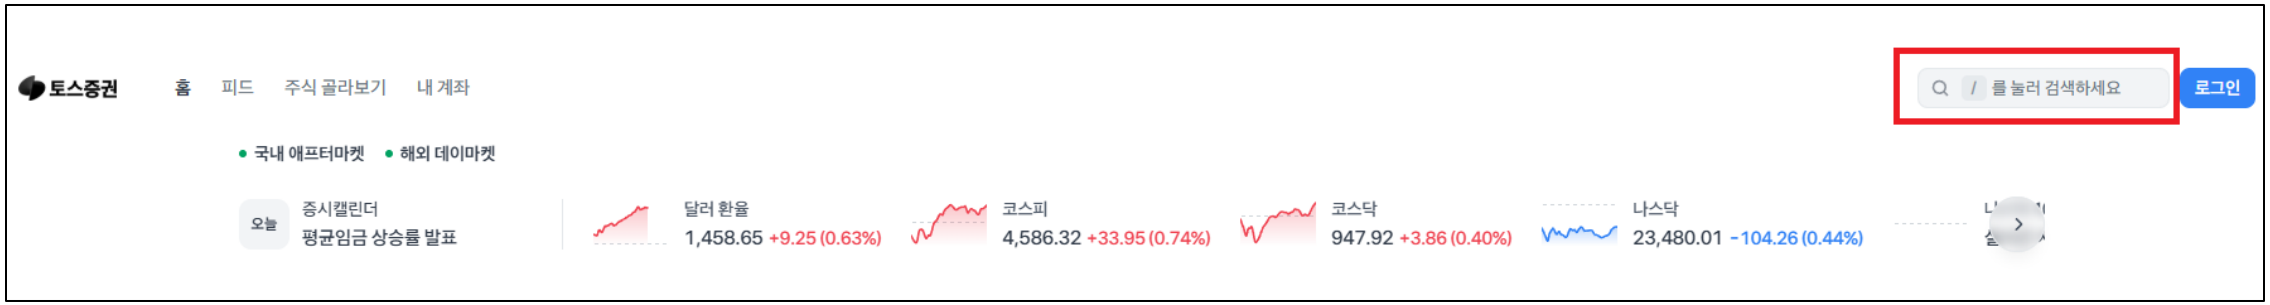

Confidential

모달창 화면 출력 (클릭 또는 / 입력)

Confidential

커뮤니티 탭 위치 확인

Confidential

댓글 위치 목록 확인

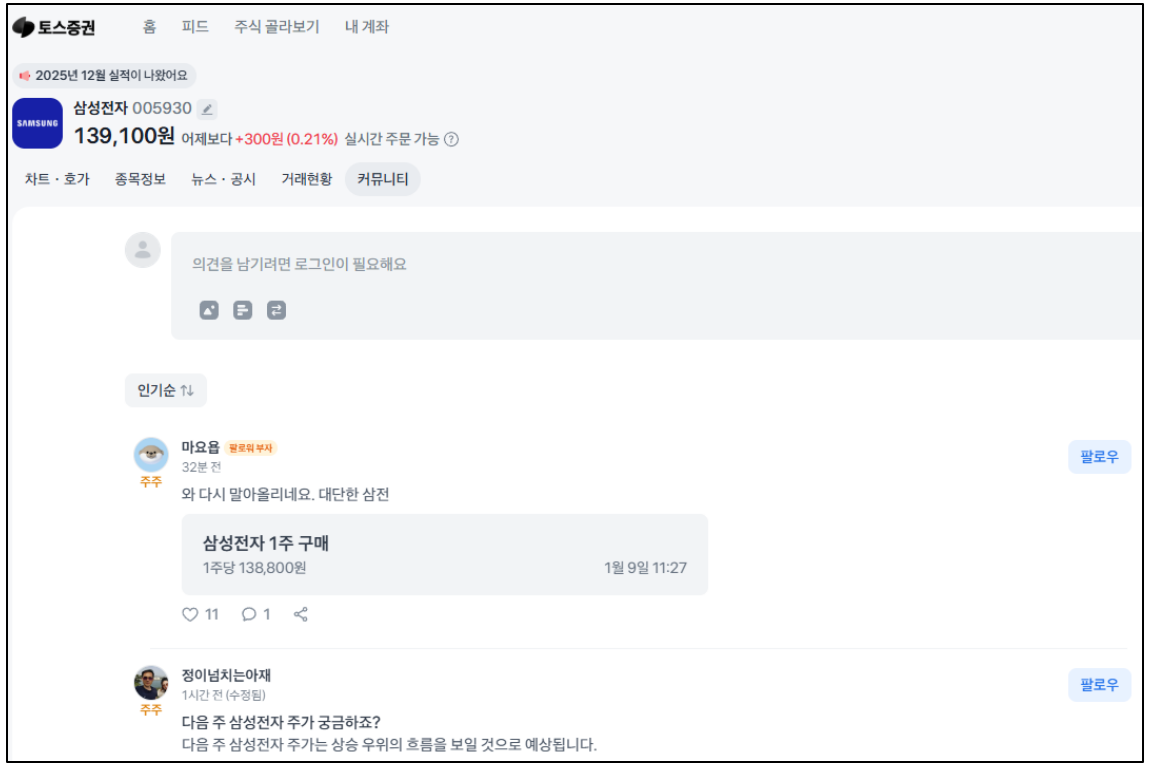

Confidential

토스 증권 데이터 수집 - 메인페이지 접속

```python
def open_toss_main():
    # 크롬 브라우저 실행
    driver = webdriver.Chrome(service=service, options=chrome_options)

    # TossInvest 메인 페이지 접속
    driver.get("https://www.tossinvest.com/")
    time.sleep(3)  # 3초간 페이지 확인

    # 페이지 로딩 완료까지 대기 (body 태그가 나타날 때까지)
    WebDriverWait(driver, 10).until(
        EC.presence_of_element_located((By.TAG_NAME, "body"))
    )
    print("[1] TossInvest 메인 페이지 접속 완료")

    # 브라우저 종료
    driver.quit()
```

Confidential

토스 증권 데이터 수집 - 회사명 검색

- 개발자 도구 -> elements -> 검색창은 Body 태그안에 존재

Confidential

토스 증권 데이터 수집 - 회사명 검색

- 클릭 또는 / 입력시 모달 출력

```
# body 태그를 선택하여 '/' 입력 → 검색창 열림
body = driver.find_element(By.TAG_NAME, "body")
body.send_keys("/")
time.sleep(1)

# 검색 입력창 요소를 찾고, 회사명을 입력 후 Enter 입력
search_input = WebDriverWait(driver, 10).until(
    EC.presence_of_element_located(
        (By.XPATH, "//input[@placeholder='검색어를 입력해주세요']")
    )
)
search_input.send_keys(company_name)
search_input.send_keys(Keys.ENTER)
time.sleep(3)
```

Confidential

토스 증권 데이터 수집 - 종목 코드 추출

- 모달 대기후, 삼성전자입력 -> 종목 코드 추출

```
# /order 페이지로 이동 완료될 때까지 대기
WebDriverWait(driver, 15).until(EC.url_contains("/order"))

# 현재 URL에서 종목 코드 추출
current_url = driver.current_url
stock_code = current_url.split("/")[
    current_url.split("/").index("stocks") + 1
]
time.sleep(1)

print(f"[3] 종목 코드 추출 완료: {stock_code}")
driver.quit()
return stock_code
```

Confidential

토스 증권 데이터 수집 - 커뮤니티 페이지 접속

- 추출한 종목 코드로 커뮤니티 접속

```
# [4] 커뮤니티 페이지 접속
community_url = f"https://www.tossinvest.com/stocks/{stock_code}/community"
driver.get(community_url)
time.sleep(1)

WebDriverWait(driver, 10).until(
    EC.presence_of_element_located((By.CSS_SELECTOR, "main article"))
)
print(f"[INFO] 커뮤니티 페이지 접속 완료: {community_url}")
```

Confidential

토스 증권 데이터 수집 - 댓글 수집

- 커뮤니티 접근 -> 댓글 수집

```
# 5. 댓글 수집 (스크롤 반복하며 누적)
comments = []
last_height = driver.execute_script("return document.body.scrollHeight")

for scroll in range(max_scroll):
    spans = driver.find_elements(
        By.CSS_SELECTOR, "article.comment span.tw-1r5dc8g0._60z0ev1"
    )

    # 새 댓글 누적 (중복 제거)
    for span in spans:
        text = span.text.strip()
        if text and text not in comments:
            comments.append(text)

    # 목표 개수 이상 모이면 종료
    if len(comments) >= limit:
        break
```

Confidential

데이터 전처리

- LLM 를 활용하여 부적절한 댓글 제거

```
prompt = f"""
다음 댓글 목록에서 부적절한 댓글(욕설, 혐오, 비방, 선정성, 과도한 비난 등)의 번호만 반환해줘.
응답은 반드시 이 형식만: [0, 2, 5] 또는 []
다른 설명이나 마크다운 없이 배열만 반환.

댓글 목록:
{numbered}
"""
```

```
# 역순으로 제거 (인덱스 밀림 방지)
for i in reversed(to_remove_idx):
    comments.pop(i)
```

Confidential

데이터 전처리

- 결측치, 특수문자, 불필요한 패턴 제거

```
def clean_with_pandas(comments):
    """결측치, 특수문자, 반복문자, 숫자, 영어, IQR 기반 이상치 제거"""
    print(f"시작 (입력", len(comments), "개)")
    df = pd.DataFrame(comments, columns=["comment"])

    # 1. 결측치 제거 (None, 공백 등)
    df = df.dropna(subset=["comment"])
    df["comment"] = df["comment"].astype(str).str.strip()
    df = df[df["comment"] != ""]

    # 2. 특수문자 제거 (한글/영문/숫자만 유지)
    df["clean"] = df["comment"].apply(lambda x: re.sub(r"[^가-힣a-zA-Z0-9\s]", "", x))
    df["clean"] = df["clean"].str.replace(r"\s+", " ", regex=True).str.strip()

    # 3. 불필요한 패턴 제거
    # - 댓글 길이를 기준으로, 정상 범위(숫자-상관)만 남김
    cond_numeric = df["clean"].str.match(r"^\d+$")
    cond_repeat = df["clean"].str.match(r"^[ㅋㅎ]+$")
    cond_english = df["clean"].str.match(r"^[A-Za-z\s]+$")
    cond_none_literal = df["clean"].str.lower() == "none"
```

Confidential

데이터 전처리

- 이상치 제거

```
# 4. 길이 기반 이상치 제거 (IQR)
# - 댓글 길이를 기준으로, 정상 범위(숫자-상관)만 남김
df["length"] = df["clean"].str.len()

if len(df) >= 5:
    q1 = df["length"].quantile(0.25)
    q3 = df["length"].quantile(0.75)
    iqr = q3 - q1
    lower = max(5, q1 - 1.5 * iqr)
    upper = q3 + 1.5 * iqr
    cond_iqr = (df["length"] < lower) | (df["length"] > upper)
    df = df[~cond_iqr]
else:
    # 너무 적을때, 3자 미만 제거
    df = df[df["length"] >= 3]

comments_cleaned = df["clean"].tolist()
```

Confidential

데이터 전처리 결과

원본 데이터 (20개)

1. 와 다시 말아올리네요. 대단한 삼전
2. 1주
3. 1월 9일 11:27
4. 다음 주 삼성전자 주가는 상승 우위의 흐름을 보일 것으로 예상됩니다. 그 근거는 다음과 같습니다 • 실적 기대감: 최근 4분기 잠정 영업이익이 20조원 발표와 함께, 2026년 연간 영업이익이 120조 원을 상회할 것이라는 낙관적 분석이 잇따르고 있습니다. • HBM4 모멘텀: 엔비디아 등 빅테크향 HBM4 공급이 가시화되면서, 메모리 반도체 부문의 수익성 개선이 강력한 동력으로 작용하고 있습니다. • 저평가 매력: 주요 증권사들이 목표 주가를 15만 원에서 최대 20만 원까지 상향 조정하며 현재 주가를 여전히 저평가 구간으로 보고 있습니다. ■ 다만, 단기 급등에 따른 피로감과, 미국 금리 정책 등 거시 경제 변수가 변동성을 키울 수 있습니다. 다음 주 월요일은 14만 2천 원~14만 3천원까지 일시 상승하겠고, 주중에는 13만 7천원 대까지 하락 가능하니, 다음 주 화요일 이후, 13만7천원~8천원대 진입 시, 과감히 매수하셔도 좋겠습니다. 오늘 장시작 전에 13만 8천 원 때까지 밀릴 거라고 예상했듯이, 오늘 13만 8천 원 근처에서 매수하셨으면 나쁘지 않았다고 봅니다. 어차피, 1월 말 15만원 근처까지 가 있을 겁니다 오늘 불🔥금에 소주 한 잔 하시죠? 더 보기

전처리 후 (17개) - (길이: 5 ~ 57)

1. 와 다시 말아올리네요 대단한 삼전
2. 1월 9일 1127
3. 믿습니다 믿어요
4. 원칙을 깼으니 대가는 감당하기 힘든 수익으로 치르게 되겠지
5. 여러분 백날 떠드셔봐야 국장의 정답은 삼전인 거아시자나여 조급해하지 말기
6. 야금야금 잘간다잉
7. 삼전은 배신 안해

Confidential

데이터 증강

```python
# 4. 데이터 증강 (GMS,OpenAI)
def augment_comments(cleaned_result):
    """전처리된 문장에서 일부 샘플 추출 후 GPT로 증강"""

    if not cleaned_result:
        print("[증강] 증강할 데이터 없음, 스킵")
        return []

    print("[증강] LLM 호출로 문장 증강 중... (입력", len(cleaned_result), "개)")

    prompt = f"""
    {cleaned_result}

    위 리스트의 각각의 문장을, 의미는 유지하면서 다르게 표현해줘.
    - 출력 형식: 대괄호 [ 로 시작해서 대괄호 ] 로 끝나는 리스트
    """

    response = run_llm(prompt)
```

전처리 후 (15개) - (길이: 5 ~ 44)

1. 와 다시 말아올리네요 대단한 삼전
2. 1월 9일 1127
3. 믿습니다 믿어요
4. 원칙을 깼으니 대가는 감당하기 힘든 수익으로 치르게 되겠지
5. 여러분 백날 떠드셔봐야 국장의 정답은 삼전인 거아시자나여 조급해하지 말기
6. 야금야금 잘간다잉
7. 삼전은 배신 안해
8. 지금 앱장이에요
9. 애프터에서 14만 찍자
10. 13밑으로 가면 추매합니다
11. 1월 9일 1630
12. 삼성전자 SK하이닉스 더 보기
13. 1월 9일 1611
14. 주주 형누님들의 저력으로 양전 했네용
15. 오늘도 아무일이 없었다

증강 데이터 (15개)

1. 삼전이 다시 한번 힘을 내네요, 정말 놀라워요
2. 1월 9일 11시 27분
3. 저는 믿고 있어요, 믿어봐요
4. 원칙을 어겼으니 그에 상응하는 큰 대가를 치르게 될 거예요
5. 여러분, 아무리 떠들어도 기본적으로 삼전이 정답이라는 걸 아시죠? 서두르지 마세요
6. 조금씩 잘 나아가고 있네요
7. 삼전은 절대裏裏裏

Confidential

이번 실습에서의 Data Pipeline

- 데이터 수집
- 데이터 전처리
- 데이터 증강
- 전체 흐름을 하나의 Pipeline으로 구성했습니다

Confidential

이번 실습의 핵심은 특정 기술이 아닙니다

- 어떻게 가져오고
- 어떻게 정리하고
- 어떻게 보강하고
- 어떻게 활용할지
- 흐름을 설계하는 사고방식을 배우는 것 입니다

왜 데이터 전처리와 증강까지 진행했을까?

Confidential

실제 프로젝트에서는 “데이터를 수집했다”로 끝나지 않습니다

- 수집된 데이터는 그대로 쓰기 어렵고 품질이 일정하지 않으며 양이 부족한 경우도 많습니다
- 그래서 데이터 전처리와 데이터 증강은 선택이 아니라 필수 단계입니다.

왜 Selenium을 선택했을까?

Confidential

데이터 수집 방식은 상황에 따라 달라집니다

- Request + BeautifulSoup : 정적 페이지, 빠르고 가벼움
- Selenium : 동적 페이지, 사용자 행동 필요
- API : 가장 안정적이지만 제공되지 않는 경우 존재

한계와 주의점

Confidential

이번 실습은 교육 목적의 웹 스크래핑 예제입니다

- 사이트 구조가 바뀌면 동작하지 않을 수 있습니다
- 로그인, 캡차, 차단 정책에는 취약합니다
- 대량 요청 시 IP 차단 위험이 있습니다
- 항상 동일한 데이터 품질을 보장하지는 않습니다

확장 방향

Confidential

이번 실습을 기반으로 다음 단계로 확장할 수 있습니다

- 다른 사이트로 크롤링 대상 변경
- 수집 데이터 DB 저장 및 자동 수집
- 감성 분석, 키워드 분석
- 시각화 대시보드
- 해당 프로젝트는 끝이 아니라 시작입니다 데이터를 수집하여 추후 시각화 할 수 있습니다

Confidential

데이터 수집에는 정해진 정답이 없습니다

- API가 있으면 API를 쓰고
- 없으면 스크래핑을 고려하고
- 그래도 부족하면 증강을 고민합니다
- 중요한 것은 ‘기술 선택’이 아니라, ‘상황 판단’입니다

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

도전 과제 소개

Confidential

데이터 크롤링 프로젝트

- 데이터 수집, 저장, 전처리, 증강 전체 파이프라인 구성을 목표로 합니다.
- 사용자 입력 -> 크롤링 -> 전처리 -> 데이터 증강 -> 결과 출력의 흐름을 하나의 웹 서비스로 완성
- 디자인은 자유롭게 구성합니다.