SAMSUNG SW AI ACADEMY FOR YOUTH

對外秘

프로젝트 명세서

AI 프로젝트

(Python 트랙)

“데이터 크롤링 프로젝트”

1 회차

對外秘

목차

1. 데이터 크롤링 프로젝트 3

1.1 목표 3

1.2 준비사항 3

1.3 작업 순서 4

1.4 요구사항 5

1.5 참고자료 13

1.6 프로젝트 결과 13

1. 데이터 크롤링 프로젝트

1.1 목표

본 프로젝트의 목표는 Django 기반 웹 애플리케이션에서 Selenium을 활용한 실시간 데이터 크롤링과 LLM 기반 데이터 증강 파이프라인을 구현하는 것이다.

- Django 웹 애플리케이션 구조를 이해하고 활용할 수 있다.
- 사용자 입력을 기반으로 서버 측에서 크롤링 로직을 실행할 수 있다.
- Selenium을 활용하여 동적 웹 페이지(토스증권)에서 데이터를 수집할 수 있다.
- 수집된 데이터를 전처리하고, LLM(GMS)을 활용해 텍스트 데이터를 증강할 수 있다.
- 원본 데이터와 가공·증강 데이터를 웹 화면에 통합 출력할 수 있다.

1.2 준비사항

1) 프로젝트 구조

- 본 프로젝트는 Django 기반 웹 애플리케이션으로 구성된다.
  - ■ 전체 시스템은 기능별 역할이 명확히 구분된 구조를 가지며, 입력 처리, 데이터 수집, 데이터 가공, 결과 출력의 흐름으로 동작한다.
  - ■ 사용자로부터 입력된 정보는 서버에서 처리되며, 외부 서비스로부터 필요한 데이터를 수집하는 과정을 포함한다.
  - ■ 수집된 데이터는 단계별 가공 과정을 거쳐 결과로 생성되며, 각 처리 단계는 독립적으로 관리되어 재사용이 가능하도록 구성한다.
  - ■ 데이터 처리 과정은 요청 시점에 실행되며, 별도의 사전 데이터 저장 없이 실시간으로 수행된다.
  - ■ 처리된 결과는 사용자가 확인할 수 있도록 웹 화면에 출력되며, 요청에 따라 동적으로 변경된다.
  - ■ 전체 시스템은 입력 -> 처리 -> 출력의 일관된 구조를 기반으로 동작한다.

2) 사용 데이터

- 토스증권 커뮤니티 댓글 데이터
  - ■ 사용자 입력 회사명 기반 검색
  - ■ 검색 결과 최상단 회사 기준
  - ■ 커뮤니티 탭의 댓글 텍스트
- 데이터는 사전에 저장되지 않으며,
  - ■ 요청 시 실시간 크롤링
  - ■ 결과는 화면에 출력
- 증강 데이터는 GMS LLM API를 통해 생성된다.

3) 개발언어 및 툴

- Python
- Django
- Selenium WebDriver
- Visual Studio Code
- 웹 브라우저 (Chrome 권장)

4) 필수 라이브러리 / 오픈소스

- django
  - ■ 웹 애플리케이션 프레임워크
- selenium
  - ■ 동적 웹 페이지 크롤링
- webdriver-manager
  - ■ ChromeDriver 자동 관리
- re
  - ■ 정규 표현식을 활용한 텍스트 전처리
- GMS LLM API
  - ■ SSAFY 내부 제공 생성형 AI API
  - ■ 텍스트 데이터 증강에 활용데이터 바인딩 및 컴포넌트 기반 UI 구성을 위한 프레임워크

1.3 작업 순서

1) 팀원과 같이 요구사항(기본/심화)을 확인한다.

2) 직접 토스 증권에 접속하여 회사 검색 및 댓글 목록 위치를 확인한다.

3) 개발 사항 및 수정(개선) 등 할 일을 정하고 역할을 분담한다.

4) 요구사항에 맞는 기능을 구현하고 테스트한다.

5) 팀원과 함께 추가적인 아이디어를 논의하고 정리한다.

6) 추가 아이디어를 적용하여 프로젝트를 완성한다.

7) 산출물을 정리하여 GitLab 에 반영한다.

1.4 요구사항

본 프로젝트는 Django 서버에서 실행되는 크롤링·데이터 가공 파이프라인 구현을 목표로 한다. 사용자 입력 -> 크롤링 -> 전처리 -> 데이터 증강 -> 결과 출력의 흐름을 하나의 웹 서비스로 완성한다.

■ 요구사항 예시 (참고용)

- 아래의 내용을 참고하여 추가적인 아이디어에 대해 요구사항을 추가 또는 수정하여 기능을 구현한다. 단, 필수 기능은 반드시 구현해야 하며 수정할 수 없다.

기능적 요구사항				
번호	분류	요구사항명	요구사항 상세	우선순위
F101	입력	회사명 입력 및 검증	사용자는 웹 화면을 통해 회사명을 입력할 수 있어야 하며, 입력값이 없는 경우 데이터 수집 절차가 수행되지 않도록 제한한다. 회사명은 일부 문자열 입력이 가능해야 한다.	필수
F102	데이터 저장	DB 스키마 구성	각 단계의 결과를 저장할 수 있도록 스키마를 구성하고 마이그레이션 과정을 수행한다.	
F103	데이터 조회	회사 검색 및 선택	입력된 회사명을 기준으로 외부 증권 서비스에서 회사 검색을 수행하며, 검색 결과가 여러 개인 경우 최상단에 노출된 회사를 자동으로 선택한다.	필수
F104	데이터 수집	커뮤니티 댓글 데이터 수집	선택된 회사의 상세 페이지로 이동한 후 커뮤니티 영역에 접근하여 댓글 텍스트 데이터를 수집한다.	필수
F105	데이터 전처리	댓글 데이터 정제	수집된 댓글 데이터에 대해 길이 기준 필터링, 특수문자 제거, 불필요한 공백 제거 등 기본적인 전처리 작업을 수행한다.	필수
F106	데이터 증강	텍스트 데이터 증강	전처리된 댓글 데이터를 기반으로 생성형 언어 모델을 활용하여 의미를	필수

			유지한 확장 텍스트 데이터를 생성한다.	
F107	데이터 통합	데이터 통합 관리	원본 댓글 데이터, 전처리 데이터, 증강 데이터를 하나의 결과 집합으로 통합하여 관리하고 출력한다.	필수
F110	데이터 분석	댓글 요약 생성	수집된 전체 댓글 데이터를 기반으로 주요 내용을 요약한 결과를 생성하여 함께 출력한다.	심화
F111	시스템 처리	예외 상황 처리 및 안내	회사 검색 결과가 없거나 댓글 데이터가 존재하지 않는 경우, 사용자에게 상태를 안내하는 메시지를 출력한다.	심화
…	…	…	…	…

1. 기본 기능 (필수)

사용자로부터 회사 이름을 입력받고, 토스증권에서 해당 회사의 댓글 데이터를 수집하는 기능을 구현한다. 전체 디자인은 자유롭게 구성한다.

1) 회사명 입력 및 검증 기능을 구현한다.

① 요구사항 번호 : F101

② 사용자로부터 회사명을 입력받는다.

③ 입력값이 없는 경우 데이터 수집 절차를 수행하지 않는다.

<그림 1> 사용자 입력 기능 결과 예시

2) **각 단계의 결과를 저장할 수 있도록 구성한다.**

① 요구사항 번호 : F102

② 데이터 수집, 전처리, 증강 각 단계의 결과를 데이터베이스에 모두 저장할 수 있도록 설계한다.

③ 저장해야 할 데이터는 다음과 같다.

- ◆ 실제종목명: 실제 매칭된 종목의 공식 명칭
- ◆ 원본 댓글 목록
- ◆ 정제 댓글 목록
- ◆ 증강 댓글 목록
- ◆ IQR 임계값 정보
- ◆ 생성 일시

3) 회사 검색 및 대상 회사를 선택한다.

④ 요구사항 번호 : F103

⑤ 입력된 회사명을 기준으로 외부 증권 서비스에서 회사를 검색한다.

◆ 토스 증권 홈페이지의 검색 과정은 아래 이미지를 참고한다.

⑥ 검색 결과 중 최상단에 노출된 회사를 자동으로 선택한다.

◆ 예시) “삼성” 검색 시 “삼성전자” 자동 검색

◆ 존재하지 않는 회사에 대한 처리는 요구사항 F111 에서 구현

⑦ [선택] 스트리밍 기능을 활용하여 크롤링 진행 상황을 적절히 출력한다.

<그림 2> 크롤링 진행 상황 출력 예시

<그림 3> 토스증권 홈페이지 - 우측 상단 검색창 클릭

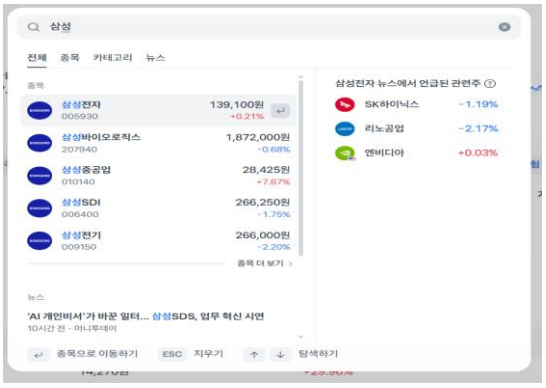

<그림 4> 토스증권 홈페이지 - 모달창 화면 (최상단 회사 자동 포커싱)

4) 커뮤니티 댓글 데이터를 수집한다.

① 요구사항 번호 : F104

② 선택된 회사의 상세 페이지에 접근하여 커뮤니티 영역으로 이동한다.

③ 커뮤니티 영역에 게시된 댓글 텍스트 데이터를 수집한다.

◆ 20 개의 데이터를 수집하도록 구성한다.

④

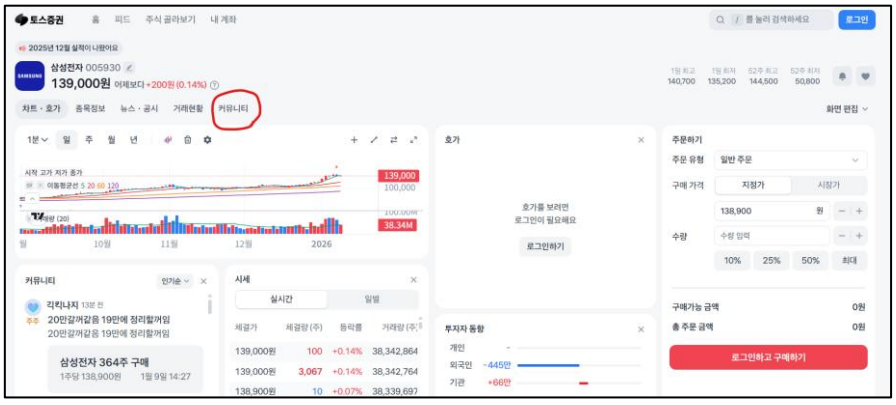

<그림 5> 토스증권 홈페이지 - 커뮤니티 탭 위치

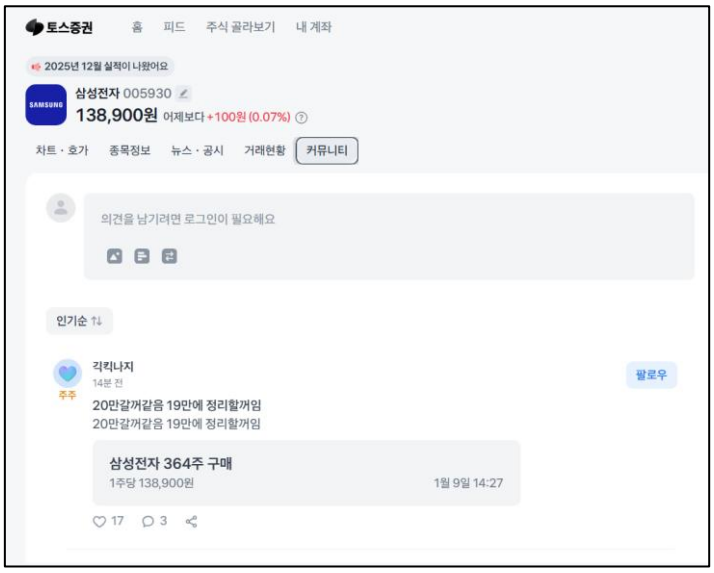

<그림 6> 토스증권 홈페이지 - 댓글 목록 위치

5) **댓글 데이터에 대한 전처리를 수행한다.**

① 요구사항 번호 : F105

② 댓글 데이터에 대한 전처리를 수행한다.

◆ 필수 전처리

✓ 결측치 혹은 길이가 너무 짧거나 긴 댓글

✓ 특수문자(의미없는 댓글) 와 불필요한 패턴(ㅋㅋㅋ 등)

✓ 부적절한 댓글 데이터 (LLM API 호출을 통하여 구현)

✓ 프롬프트 예시: 다음 댓글 목록에서 부적절한 댓글(욕설, 혐오, 비방, 선정성, 과도한 비난 등)의 번호(0 부터 시작)만 JSON 배열로 알려줘

◆ 이후 데이터 증강 및 통합 단계에서 활용 가능하도록 구성한다.

③ 결과를 화면에서 확인할 수 있도록 구성한다.

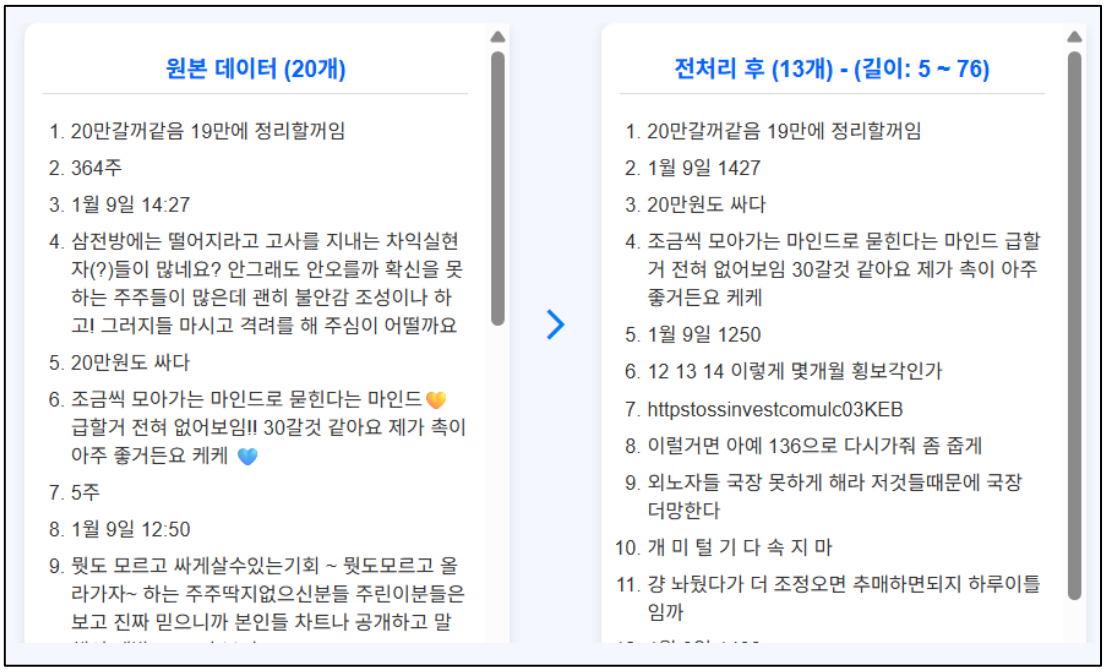

<그림 7> 원본 데이터 및 전처리 후 데이터 출력 결과 예시

6) **텍스트 데이터 증강을 수행한다.**

① 요구사항 번호 : F106

② 전처리된 댓글 데이터를 기반으로 텍스트 데이터를 증강한다.

③ 기존 댓글의 의미를 유지한 상태로 확장된 데이터를 생성한다.

④ 결과를 화면에서 확인할 수 있도록 구성한다.

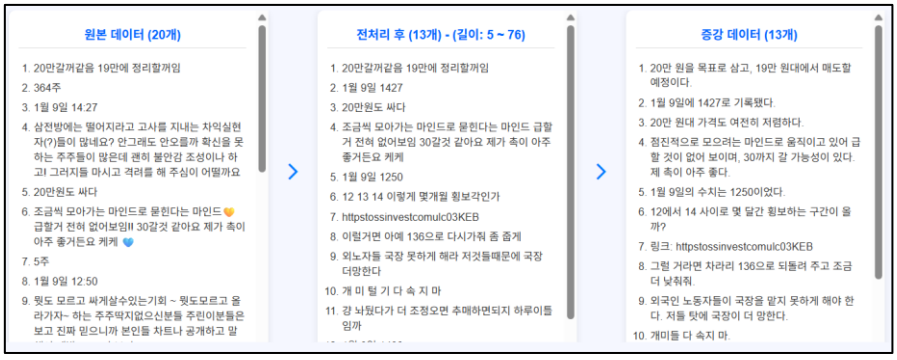

<그림 8> 증강 데이터 출력 결과 예시

7) **통합된 데이터 결과를 출력한다.**

① 요구사항 번호 : F107

② 원본 데이터, 전처리 데이터, 증강 데이터를 하나의 결과 집합으로 통합한다.

③ 단계별 데이터 구분이 가능하도록 관리한다.

<그림 9> 통합 데이터 출력 결과 예시

2. 심화 기능 (선택)

심화 기능은 수집된 댓글 데이터를 요약하여 의미 있는 정보를 도출하고, 데이터 미존재 등 예외 상황에 대한 안내를 제공함으로써 실제 서비스 환경을 고려한 데이터 수집·처리 흐름을 확장 구현하는 것을 목표로 한다.

8) 댓글 데이터를 요약하여 제공한다.

① 요구사항 번호 : F110

② 수집된 전체 댓글 데이터를 기반으로 주요 내용을 요약한다.

③ 요약 결과를 기존 데이터와 함께 출력한다.

- ◆ 출력 화면은 자유롭게 선택한다.
- ◆ 예시 1) 화면 하단 텍스트로 출력
- ◆ 예시 2) 요약 버튼 클릭 시 화면에 출력 (바이브 코딩으로 구현)

9) 예외 상황에 대한 안내를 제공한다.

① 요구사항 번호 : F111

② 회사 검색 결과 또는 댓글 데이터가 존재하지 않는 경우를 처리한다.

③ 사용자에게 현재 상태를 안내하는 메시지를 출력한다.

1.5 참고자료

- Django 공식 문서
  https://docs.djangoproject.com/

- Selenium 공식 문서
  https://www.selenium.dev/documentation/

- MDN Web Docs - 정규 표현식(Regular Expression)
  https://developer.mozilla.org/ko/docs/Web/JavaScript/Guide/Regular_expressions

1.6 프로젝트 결과

아래 내용들을 모두 포함하여 GitLab 에 업로드한다.

프로젝트 이름은 프로젝트 번호 + _pjt 로 지정한다. (ex) 01_pjt)

■ **산출물과 제출**

1) 구현 소스 코드

◆ 프로젝트 전체 소스 코드를 제출한다.

2) 실행 결과 캡처본

◆ 각 요구사항에 대한 실행 결과 화면을 캡처한다.

3) README.md

◆ 구현 기능 설명, 학습 내용, 느낀 점을 반드시 포함한다.

- 以上